

Modelo de Pronóstico de Opciones de Pago

 **Bancolombia**



Un Banco que mejora sus procesos

Construir una solución analítica E2E que permita poner en producción un modelo que genere un indicador de propensión a la aceptación de opción de pago de cada obligación de un cliente en mora.

1. Automatizar el proceso de análisis para predecir la respuesta del cliente en la gestión de opciones de pago.
2. Utilizar datos financieros, de comportamiento y de interacción con los clientes para realizar una predicción precisa de la respuesta del cliente.
3. Generar un archivo de predicción con el formato requerido para la evaluación del modelo.

Una historia de crecimiento, innovación y éxito

1) Carga de Datos desde archivos Excel (Datos demográficos y financieros del cliente, historial de pagos y cuotas y datos para probar el modelo.)

```
# Archivos disponibles
files = {
    'base_pivot': 'prueba_op_base_pivot_var_rpta_alt_enmascarado_trtest.csv',
    'probabilidad_oblig': 'prueba_op_probabilidad_oblig_base_hist_enmascarado_completa.csv',
    'master_customer': 'prueba_op_master_customer_data_enmascarado_completa.csv',
    'cuotas_pagos_hist': 'prueba_op_maestra_cuotas_pagos_mes_hist_enmascarado_completa.csv',
    'prueba_op': 'prueba_op_base_pivot_var_rpta_alt_enmascarado_oot.csv'
}

# Cargar los archivos en DataFrames
df_base_pivot = pd.read_csv(os.path.join(data_path, files['base_pivot']))
df_probabilidad_oblig = pd.read_csv(os.path.join(data_path, files['probabilidad_oblig']))
df_master_customer = pd.read_csv(os.path.join(data_path, files['master_customer']))
df_cuotas_pagos_hist = pd.read_csv(os.path.join(data_path, files['cuotas_pagos_hist']))
df_prueba_op = pd.read_csv(os.path.join(data_path, files['prueba_op']))
```

2) Estado actual de la información (formato de las variables, Estadísticas generales, validación de duplicados, frecuencias y porcentajes)

```
def validar_dataframe(df, nombre_df, columnas_duplicadas=None):
    """
    Realiza validaciones comunes Los DataFrames.

    Args:
        df (pd.DataFrame): El DataFrame a validar.
        nombre_df (str): EL nombre del DataFrame para mostrar en los resultados.
        columnas_duplicadas (list, optional): Lista de columnas para verificar duplicado
    """
    print(f"\n--- Validaciones para: {nombre_df} ---")

    # Información general del DataFrame
    print(f"\nInformación del DataFrame:")
    df.info()

    # Conteo de valores nulos
    null_counts = df.isnull().sum()
    print(f"\nConteo de valores nulos por columna:")
    print(null_counts)

    # Estadísticas descriptivas
    print(f"\nEstadísticas descriptivas:")
    print(df.describe())

    # Detección de duplicados en todo el DataFrame
    duplicados_total = df.duplicated()
    hay_duplicados = duplicados_total.any()
    num_duplicados = duplicados_total.sum()

    print(f"\n¿Existen duplicados en el DataFrame? {hay_duplicados}")
    print(f"Número total de filas duplicadas: {num_duplicados}")

    if hay_duplicados:
        print(f"\nFilas duplicadas:")
        print(df[duplicados_total])

    # Detección de duplicados en columnas específicas
    if columnas_duplicadas:
        duplicados_columnas = df.duplicated(subset=columnas_duplicadas).sum()
```

4) Creación del modelo de Aprendizaje Automático y predicción de los datos de prueba

```
# Modelo Random Forest con regularización
rf_model = RandomForestClassifier(
    n_estimators=100,      # Número de árboles
    max_depth=10,          # Profundidad máxima de los árboles
    min_samples_split=10,  # Mínimo de muestras para dividir un nodo
    min_samples_leaf=5,    # Mínimo de muestras en una hoja
    random_state=42
)
rf_model.fit(X_train, y_train)

# Modelo Gradient Boosting con regularización
gb_model = GradientBoostingClassifier(
    n_estimators=100,      # Número de iteraciones
    learning_rate=0.05,    # Tasa de aprendizaje
    max_depth=3,           # Profundidad máxima de los árboles
    min_samples_split=10,  # Mínimo de muestras para dividir un nodo
    min_samples_leaf=5,    # Mínimo de muestras en una hoja
    random_state=42
)
gb_model.fit(X_train, y_train)
```

3) Imputación de valores faltantes, creación de variables derivadas y transformaciones logarítmicas, Winsorización para manejar outliers, agrupación de categorías poco frecuentes y codificación One-Hot para variables categóricas, selección de variables relevantes para el modelo.

```
# Crear variables de tendencia (cambio porcentual respecto al mes anterior)
df_base_pivot['tendencia_dias_mora'] = df_base_pivot.sort_values(by=['nit_enmascarado', 'num_oblig_orig_enmascarado', 'num_oblig_enmascarado', 'fecha']).groupby(
    ['nit_enmascarado', 'num_oblig_orig_enmascarado', 'num_oblig_enmascarado']).shift(1)
df_base_pivot['tendencia_dias_mora'] = df_base_pivot['tendencia_dias_mora'].replace([np.inf, -np.inf, np.nan], 0)
df_base_pivot['tendencia_vlr_obligacion'] = df_base_pivot.sort_values(by=['nit_enmascarado', 'num_oblig_orig_enmascarado', 'num_oblig_enmascarado', 'fecha']).groupby(
    ['nit_enmascarado', 'num_oblig_orig_enmascarado', 'num_oblig_enmascarado']).shift(1)
df_base_pivot['tendencia_vlr_obligacion'] = df_base_pivot['tendencia_vlr_obligacion'].replace([np.inf, -np.inf, np.nan], 0)
df_base_pivot['tendencia_vlr_vencido'] = df_base_pivot.sort_values(by=['nit_enmascarado', 'num_oblig_orig_enmascarado', 'num_oblig_enmascarado', 'fecha']).groupby(
    ['nit_enmascarado', 'num_oblig_orig_enmascarado', 'num_oblig_enmascarado']).shift(1)
df_base_pivot['tendencia_vlr_vencido'] = df_base_pivot['tendencia_vlr_vencido'].replace([np.inf, -np.inf, np.nan], 0)
```

Una historia de crecimiento, innovación y éxito



Data:

Rpta_alt_enm
ascarado_trte
st

- **Tendencia de Mora (Días de Mora):** Evalúa el cambio porcentual de los días de mora mes a mes, reflejando el comportamiento de la deuda vencida.
 - **Tendencia del Valor de la Obligación:** Mide el cambio porcentual en el monto total de la deuda mensual de los clientes.
 - **Tendencia del Valor Vencido:** Muestra el cambio porcentual del valor de la deuda vencida, indicando posibles incrementos en la mora.
 - **Tendencia de Endeudamiento:** Mide los cambios en el nivel de endeudamiento de los usuarios a lo largo del tiempo.
 - **Tendencia del Valor de Cuota Mensual:** Muestra la variación en el valor mensual de las cuotas, reflejando la carga financiera para el cliente.
 - **Tasa de Cumplimiento de Pago Total:** Mide la efectividad del cliente en pagar el total de su deuda en comparación con el monto total adeudado.
 - **Tasa de Cumplimiento de Cuota:** Indica el porcentaje de clientes que pagan su cuota mensual frente al monto de la cuota correspondiente.
 - **Tasa de Mora respecto a la Obligación:** Relaciona el valor vencido con el monto total de la deuda, evaluando el riesgo de mora.
 - **Tasa de Contacto Efectivo:** Mide la efectividad de los contactos realizados con los clientes en relación con las gestiones totales.
 - **Frecuencia y Proporción de Aceptación de Opciones de Pago:** Evalúa cuántos clientes aceptan las opciones de pago propuestas en relación con el total de contactos realizados.
- y otras adicionales a nivel de variables de tendencia, tasas, rezagos, agregaciones, manejo de outliers

Una historia de crecimiento, innovación y éxito



Data:

master_customer_data

- **Imputación de valores** faltantes en variables como tipo_vivienda, nivel_academico, num_hijos, y personas_dependientes.
- **Relación entre ingresos y egresos** (relacion_ing_egresos) para medir capacidad financiera.
- **Relación entre activos y pasivos** (relacion_act_pas) para evaluar nivel de endeudamiento.
- **Porcentaje de patrimonio sobre activos** (porc_patrimonio) para evaluar solvencia.
- **Codificación cíclica de mes** (month_sin, month_cos) para capturar patrones estacionales.
- **Transformación logarítmica de variables numéricas** (ej. total_ing, tot_activos) para normalizar distribuciones.
- **Winsorización** de valores atípicos en variables numéricas clave como edad_cli e ingresos.
- **Codificación One-Hot** de variables categóricas como genero_cli, estado_civil, ocup, sector, entre otras.
- **Carga familiar** (carga_familiar) para medir la presión económica de dependientes.
- **Agrupación** de categorías menos frecuentes en "Otros" para mejorar la manejabilidad de variables categóricas.

Una historia de crecimiento, innovación y éxito



Data:

maestra_cuotas_pagos

- **Variables Categóricas Codificadas:** Se realizaron transformaciones One-Hot Encoding para las variables 'producto', 'aplicativo', 'segmento', y 'marca_pago', agrupando categorías con baja frecuencia en "Otros", con el fin de preparar datos para modelos predictivos.
- **Winsorización de Variables Numéricas:** Se aplicó winsorización a las variables 'valor_cuota_mes', 'pago_total', y 'porc_pago' para mitigar el impacto de los outliers y mejorar la estabilidad del modelo.
- **Manipulación de Fechas:** Se extrajeron componentes de fecha (año_corte, mes_corte) y se calculó la diferencia en días entre 'fecha_corte' y 'fecha_pago_maxima', proporcionando indicadores de comportamiento temporal de los pagos.
- **Variables de Rezago:** Se generaron variables de rezago para el pago total y porcentaje de pago, como 'lag_porc_pago_1m' y 'media_movil_pago_3m', para evaluar el comportamiento de pago a lo largo del tiempo.
- **Cumplimiento de Pago:** Se creó una variable binaria 'cumplimiento_pago', indicando si el pago total es igual o mayor que la cuota mensual, para evaluar el cumplimiento de las obligaciones.
- **Eliminación de Valores Nulos:** Se eliminaron filas con valores nulos generados por las variables de rezago, asegurando la integridad de los datos para análisis posteriores.
- **Variables Seleccionadas:** Las variables seleccionadas incluyen tanto datos originales como las nuevas variables procesadas, como componentes de fecha, rezagos, y las variables codificadas, lo que facilita el análisis de tendencias y comportamientos de pago.

Una historia de crecimiento, innovación y éxito




Data:

probabilidad_
oblig_base


- **year, month, quarter:** Extraídos de fecha_corte para análisis temporal.
- **lag_prob_propension_1m:** Rezago de la probabilidad de propensión 1 mes atrás.
- **lag_prob_propension_3m:** Rezago de la probabilidad de propensión 3 meses atrás.
- **trend_prob_prop:** Cambio porcentual de prob_propension respecto al mes anterior.
- **trend_prob_alrt:** Cambio porcentual de prob_alrt_temprana respecto al mes anterior.
- **Manejo de nulos:** Relleno de nulos en variables de rezago y tendencia con valor 0.
- **freq_obligation:** Frecuencia de aparición de cada obligación por cliente.
- **One-Hot Encoding en lote:** Codificación de la variable categórica lote.
- **Ordenamiento de datos:** Los datos se ordenan por cliente y obligación para crear variables de rezago y tendencia.
- **Preprocesamiento:** Preparación de datos para análisis y modelado predictivo.

Una historia de crecimiento, innovación y éxito

Unificación de la información en un solo dataset para se modelado



Una historia de crecimiento, innovación y éxito



Variables seleccionadas una vez se realiza regularización, importancia mediante los modelos de ML

Variables de aceptación y pago:

- frecuencia_aceptacion, proporcion_aceptacion, porc_pago_mes_max, cumplimiento_pago, valor_cuota_mes, pago_total, porc_pago.

• Variables de comportamiento de pago:

- descripcion_ranking_mejor_ult_PLAN DE PAGO, descripcion_ranking_mejor_ult_otros, marca_alt_rank_otros, marca_alt_apli_SI, marca_agrupada_rgo_MANTENIMIENTO, marca_agrupada_rgo_otros, marca_pago_Sin pago.

• Variables temporales:

- año_corte, mes_corte, dias_diferencia_pago, month_sin, month_cos.

• Variables de rendimiento financiero:

- relacion_ing_egresos, relacion_act_pas, porc_patrimonio, carga_familiar.

• Probabilidades y riesgos:

- prob_propension, prob_alrt_temprana, prob_auto_cura.

• Variables de rezago y tendencia de pago:

- lag_porc_pago_1m, media_movil_pago_3m, lag_prob_propension_1m, lag_prob_propension_3m, trend_prob_prop, trend_prob_alrt.

• Frecuencia de obligaciones:

- freq_obligation.

• Variables categóricas de grupo (lote):

- lote_1, lote_2, lote_3.

• Variables relacionadas con el comportamiento histórico:

- descripcion_ranking_mejor_ult_PLAN DE PAGO, descripcion_ranking_mejor_ult_otros, marca_alt_rank_otros, marca_alt_apli_SI.

- Indicadores de tendencias de pago y comportamiento histórico:

- trend_prob_prop, trend_prob_alrt, lag_prob_propension_1m, lag_prob_propension_3m

Una historia de crecimiento, innovación y éxito

Resultados Random Forest:				
Accuracy: 0.9760				
AUC: 0.9975				
Reporte de Clasificación:				
	precision	recall	f1-score	support
0	0.97	0.98	0.98	59223
1	0.98	0.97	0.97	54428
accuracy			0.98	113651
macro avg	0.98	0.98	0.98	113651
weighted avg	0.98	0.98	0.98	113651

Precisión del modelo: El modelo Random Forest tiene una precisión global de 97.6%, indicando un rendimiento excelente.

AUC elevada: Un AUC de 0.9975 muestra que el modelo tiene una alta capacidad para distinguir entre las clases.

Clasificación balanceada: El modelo presenta un buen equilibrio entre las clases 0 y 1, con f1-scores de 0.98 y 0.97, respectivamente.

Excelente Recall: El recall para la clase 0 (0.98) y la clase 1 (0.97) demuestra que el modelo detecta la mayoría de los casos relevantes.

Resultados Gradient Boosting:				
Accuracy: 0.9702				
AUC: 0.9968				
Reporte de Clasificación:				
	precision	recall	f1-score	support
0	0.96	0.98	0.97	59223
1	0.98	0.96	0.97	54428
accuracy			0.97	113651
macro avg	0.97	0.97	0.97	113651
weighted avg	0.97	0.97	0.97	113651

Una historia de crecimiento, innovación y éxito

Variables Importantes	Importancia
proporcion_aceptacion	0.381719
marca_alt_apli_SI	0.207682
frecuencia_aceptacion	0.138581
marca_agrupada_rgo_otros	0.0864995
marca_pago_Sin pago	0.0712608
marca_agrupada_rgo_MANTENIMIENTO	0.0323155
descripcion_ranking_mejor_ult_otros	0.0236659
descripcion_ranking_mejor_ult_PLAN DE PAGO	0.0218454
porc_pago_mes_max	0.018127
marca_alt_rank_otros	0.0129701
cant_acuerdo	0.00533296

Importancia de "proporcion_aceptacion": La variable más relevante, con un impacto significativo de 30.36% en la predicción.

Frecuencia de aceptación: La "frecuencia_aceptacion" es la segunda variable más importante, con un peso de 16.52%.

Marca de aplicación: La variable "marca_alt_apli_SI" tiene un peso relevante del 15.33%, indicando la influencia de la marca en la predicción.

Variables de pago: "marca_pago_Sin pago" (6.5%) y "marca_agrupada_rgo_otros" (7.9%) también son factores clave en la clasificación.

Variables menos influyentes: Variables como "prob_auto_cura" y "trend_prob_prop" tienen baja importancia en el modelo.

Desempeño global: El modelo tiene un rendimiento robusto y consistente, adecuado para tomar decisiones informadas en base a los datos.

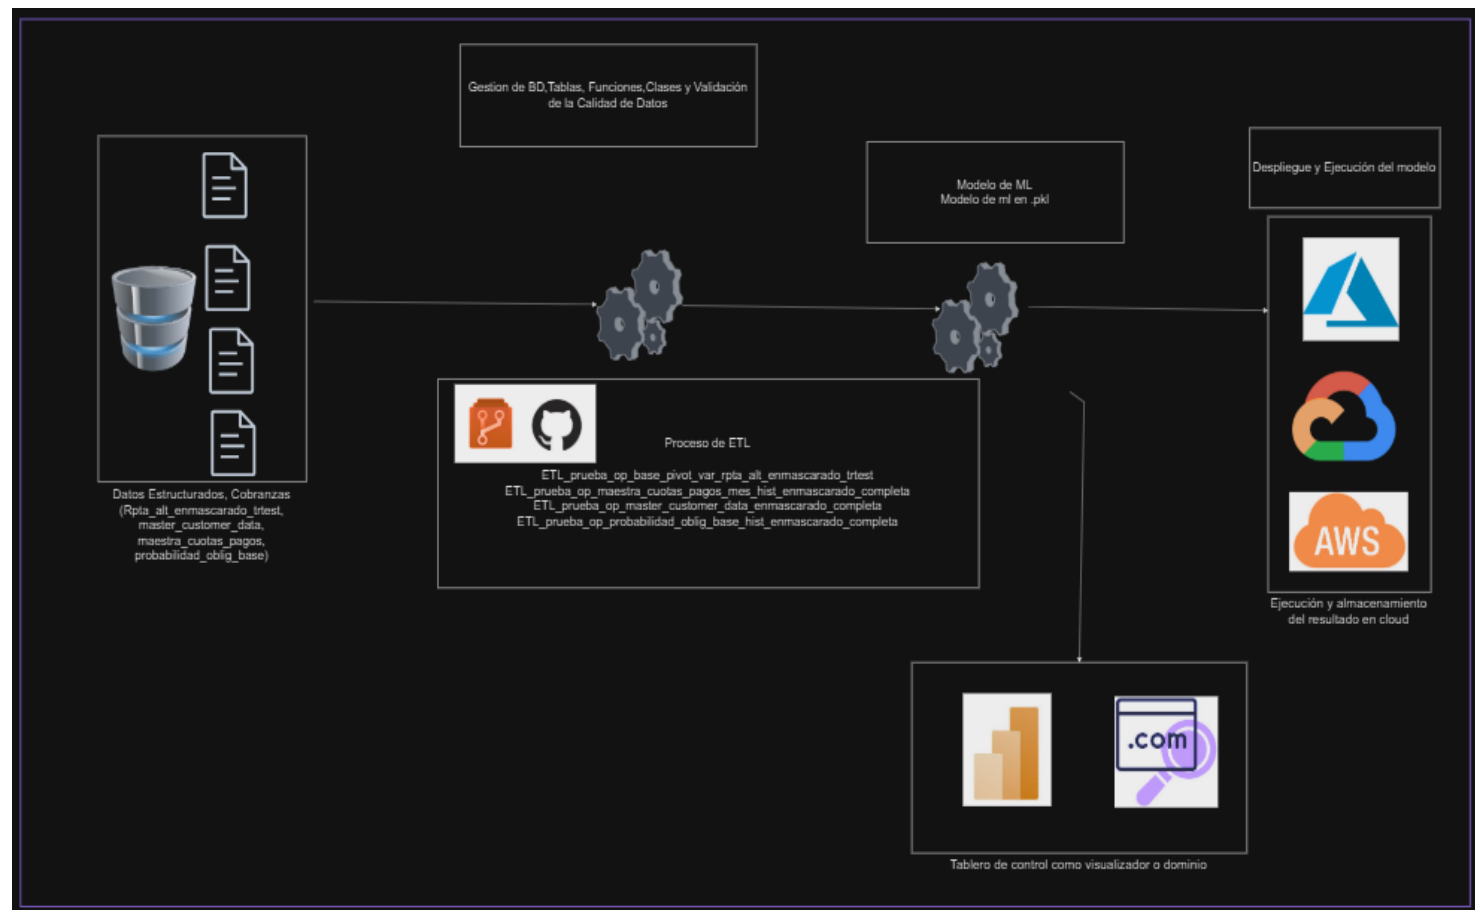
Una historia de crecimiento, innovación y éxito

Conexión de Datos: Conectar los datos desde bases de datos o archivos planos (CSV, Parquet) mediante scripts en Python o R, gestionando las credenciales de acceso de manera segura.

Repositorio de Código: Guardar el código fuente del proceso ETL y el modelo en un repositorio de código (como GitHub o GitLab) para control de versiones y colaboración.

Desarrollo del Modelo: Desarrollar y entrenar el modelo utilizando librerías como Scikit-learn, TensorFlow o PyTorch, según la complejidad del problema.

Contenerización: Crear un contenedor Docker que incluya todas las dependencias necesarias para ejecutar el modelo, garantizando portabilidad y escalabilidad.



Una historia de crecimiento, innovación y éxito

Despliegue del Modelo: Desplegar el modelo en la nube (AWS, GCP, Azure) usando servicios como AWS SageMaker, GCP AI Platform, o Azure ML para gestión de modelos.

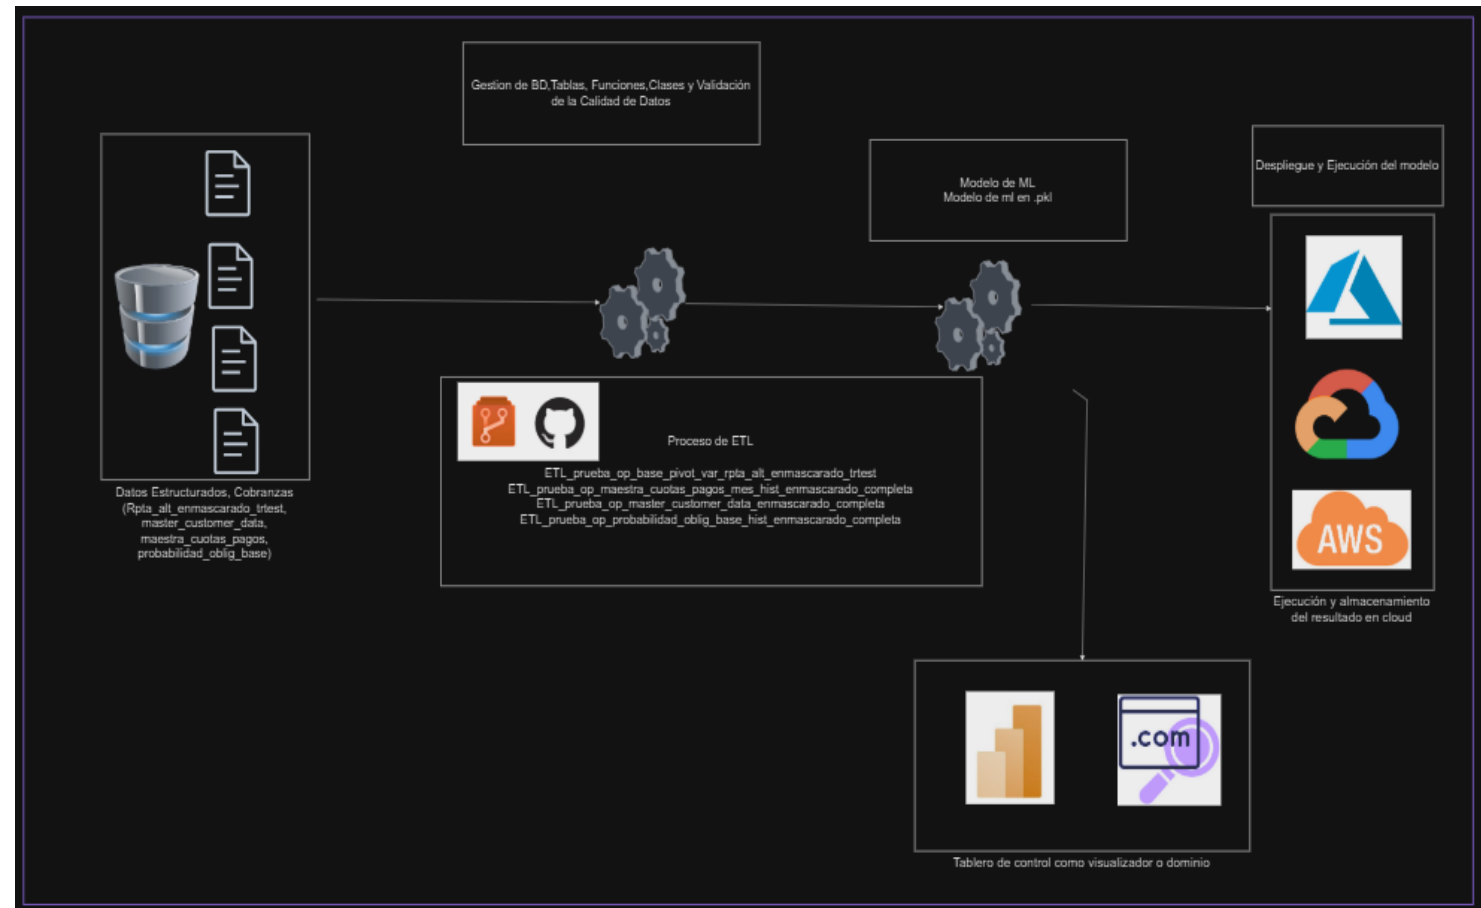
Despliegue del Proceso ETL: Desplegar el pipeline ETL en la nube utilizando servicios como AWS Glue, GCP DataFlow, o Azure Data Factory para automatizar la extracción, transformación y carga de los datos.

Automatización y Programación: Programar el flujo ETL para que se ejecute periódicamente utilizando servicios de orquestación como AWS Step Functions, Airflow en GCP, o Azure Logic Apps.

Almacenamiento en la Nube: Guardar los datos procesados y los resultados generados en un almacenamiento en la nube (AWS S3, GCS, Azure Blob) para facilitar su acceso y consulta.


Visualización de Resultados: Configurar herramientas de visualización como Power BI, Tableau, o dashboards personalizados para permitir a los usuarios consultar los resultados de manera interactiva.

Consulta de Datos: Proporcionar acceso a los usuarios finales a los datos almacenados en la nube a través de una interfaz web o herramientas de BI, permitiendo consultas en tiempo real.



Una historia de crecimiento, innovación y éxito

Se propone un tablero de control en Power BI o un dominio web que centraliza información clave para la toma de decisiones estratégicas en el proceso de cobranzas. Este tablero mostrará el número de **clientes que aceptan la opción de pago**, permitiendo identificar patrones de aceptación y mejorar las estrategias de negociación. Se incluirá el **valor total a ser pagado** y la **cartera recuperada**, proporcionando visibilidad sobre el impacto financiero de las acciones realizadas. También se visualizarán los **clientes que no aceptan la opción**, para enfocarse en nuevos acercamientos. El tablero incluirá el número de **clientes a ser contactados** y su **información de perfil**, como frecuencia de aceptación y relación de ingresos y egresos, lo que permitirá personalizar las estrategias de contacto. Esta solución automatizada ofrece **actualización en tiempo real**, facilitando un monitoreo continuo de los resultados y la eficiencia del equipo de cobranzas.



Gracias !!!

Sebastian Echeverri Parra

 **Bancolombia**

